



TECNOLÓGICO
NACIONAL DE MÉXICO



Instituto tecnológico de Culiacán

Sistema de Riego Proactivo Basado en Inteligencia Artificial, Monitoreo Fisiológico y Morfológico

Materia:

Topicos de Inteligencia Artificial

Integrantes:

Ramirez Medina Cristian Andrea
Castro Figueroa Daniel Sebastian

Maestro:

Dr. Mora Felix Zuriel Dathan

Repositorio: <https://github.com/DanielSdc/TopicosIA>

Índice

| | | |
|-----------|--|-----------|
| 1 | Introducción | 2 |
| 2 | Objetivo General | 3 |
| 3 | Objetivos específicos | 3 |
| 4 | Justificación | 4 |
| 5 | Alcance | 4 |
| 6 | Desarrollo | 6 |
| 6.1 | Desafío en México | 6 |
| 6.2 | Soluciones actuales | 6 |
| 6.2.1 | Sensores e IoT | 6 |
| 6.2.2 | Automatización y Control | 7 |
| 6.2.3 | Inteligencia Artificial | 7 |
| 6.2.4 | Tecnologías en la nube (AWS) | 7 |
| 6.3 | Antecedentes y Casos Relevantes | 8 |
| 6.3.1 | Aplicaciones Reales | 8 |
| 6.4 | Desafíos y brechas | 8 |
| 7 | Propuesta | 10 |
| 7.1 | El Sistema de Riego Proactivo consta de 3 capas: | 10 |
| 7.1.1 | Capa 1: Obtención de datos | 10 |
| 7.1.2 | Capa 2: Análisis de datos | 11 |
| 7.1.3 | Capa 3: Accionar | 12 |
| 8 | Impacto | 14 |
| 8.1 | Impacto económico | 14 |
| 8.2 | Impacto ambiental | 14 |
| 9 | Cronograma de actividades | 15 |
| 10 | Conclusiones | 17 |

1 Introducción

El agua es uno de los insumos más críticos en la vida diaria, y más aún en el sector agrícola, y en tiempos modernos es uno de los recursos más explotados, ya sea por las diferentes crisis climáticas o por el mal uso y desperdicio que le damos. En México al contar con un ciclo hidrológico tan marcado en sus distintas regiones, provoca que el sector agrícola resienta la escasez del agua. Ante esta problemática asegurar el uso justo de agua ya no es meramente una estrategia económica, sino ambiental.

En este proyecto de investigación se exploraran las diferentes soluciones existentes que se han aplicado utilizando Inteligencia artificial, se evaluará su efectividad, con el objetivo proponer posibles mejoras o una nueva solución, y el impacto que puede llegar a tener esta.

2 Objetivo General

Diseñar y describir la arquitectura de un sistema de riego proactivo inteligente que, basado en un análisis de las tecnologías actuales, que logre optimizar el uso del agua, energía y fertilizantes, a la vez que se brinda una alternativa a las brechas detectadas en estos sistemas.,

3 Objetivos específicos

1. Diseñar la arquitectura del hardware para la obtención de datos mediante distintos tipos de sensores y agrupamientos.
2. Modelar una arquitectura de datos escalable en la nube para el procesamiento, almacenamiento y análisis de los datos.
3. Especificar el modelo de Machine learning, capaz diagnosticar el estado del cultivo y generar recomendaciones.
4. Automatizar el proceso de riego en base a las recomendaciones del modelo.
5. Especificar los requisitos del dashboard del usuario.

4 Justificación

La agricultura es el sector que más demanda agua en México, llegando a representar el 76% del consumo de agua nacional según indicó Efrain Morales Lopez, director general de la CONAGUA [1]. Además la CONAGUA señaló que el 57% del agua destinada al sector agrícola es desperdiciada por infraestructuras de riego ineficientes [2].

Bajo este contexto, la inteligencia artificial, sensores e imágenes satelitales surgen como herramientas para optimizar el uso del agua en el sector agrícola, al tener la capacidad de analizar estos volúmenes de datos tan grandes, para poder predecir y mejorar los patrones de riego de forma automática en base a las necesidades del cultivo y el ambiente, y no solo minimizar el desperdicio de agua e impacto ambiental, si no también, poder mejorar la salud del cultivo (resistencia a enfermedades, crecimiento más uniforme, mejor coloración en las hojas y menor mortalidad en plántulas jóvenes) en hasta un 12% [3].

5 Alcance

El presente proyecto se limita al **diseño conceptual y la especificación técnica** de un sistema de riego proactivo. El resultado final será un documento de diseño detallado que servirá como base para un futuro desarrollo físico y programación.

Lo que si se llevará a cabo

- **Investigación y análisis:** Un estudio de las tecnologías y soluciones de riego inteligente existentes para identificar brechas y oportunidades.
- **Especificación de hardware:** La definición de los sensores, microcontroladores y demás componentes necesarios.
- **Arquitectura en la nube:** El diseño del flujo de datos y la especificación de los servicios de AWS a utilizar para el procesamiento, almacenamiento y análisis.
- **Definición del modelo de IA:** La descripción conceptual del tipo de modelo de Machine Learning, los datos que utilizará y el proceso de entrenamiento y despliegue.
- **Lógica de automatización:** El diseño del mecanismo que conecta las recomendaciones del modelo de IA con el sistema de riego.

Lo que no se llevará a cabo

- La **compra o construcción física** de un prototipo de hardware.
- El **desarrollo o programación** del software, las funciones Lambda o el dashboard.
- La **recolección de datos reales** en campo ni el entrenamiento de un modelo de IA funcional.
- Pruebas de **implementación a largo plazo** o mantenimiento del sistema.

6 Desarrollo

Bajo un contexto de escasez hídrica a nivel mundial y crisis climática, la gestión del agua se ha vuelto algo fundamental para la sostenibilidad ambiental y estabilidad económica en cualquier país, en este panorama es donde toma gran relevancia el sector agrícola debido a su rol como el principal consumidor de agua.

6.1 Desafío en México

Datos oficiales señalan que el 76% del total de agua es destinada al agropecuario, esta a su vez se usa principalmente para el riego de cultivos y ganadería, pero el mayor problema no reside en que un solo sector acapare la mayoría de un recurso tan limitado, si no, que se estima que el 57% de esta es desperdiciada, ya sea por infraestructuras obsoletas o prácticas inefficientes.

Esta inefficiencia en el uso del agua solo se ve agravado por el cambio climático, y México a ser un territorio altamente árido es muy propenso a sequías, solo en 2024 hubo períodos donde el 75% del territorio nacional estaba bajo algún nivel de sequía [4].

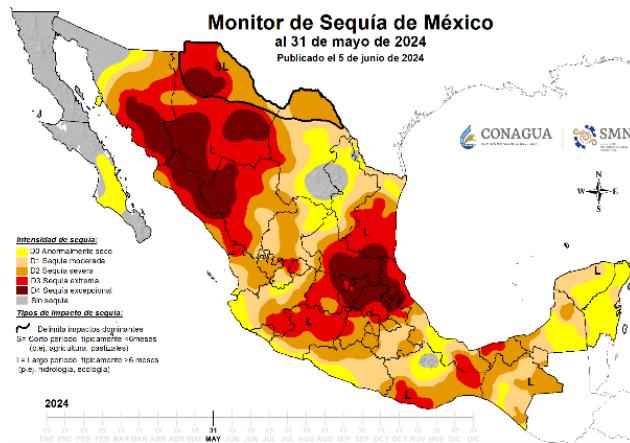


Figura 1: Mapa de sequía México, Periodo 31 de Mayo, 2024.

6.2 Soluciones actuales

El término de “Riego Inteligente” se refiere a aplicar la cantidad de agua necesaria, esto se logra a partir de un sistema que utiliza herramientas tecnológicas avanzadas, como lo son:

6.2.1 Sensores e IoT

- **Sensores de humedad, temperatura y salinidad:** capturan datos del suelo en tiempo real, esenciales para medir la disponibilidad de agua en la raíz y ajustar el riego.

- **IoT:** facilita la conexión de sensores con plataformas de gestión y extracción de datos, usando redes como LoRaWAN para comunicación de bajo consumo en entornos rurales.

6.2.2 Automatización y Control

- Los sistemas automatizados cuentan con controladores (locales o basados en la nube), válvulas inteligentes y aplicaciones móviles para supervisión y control remoto del riego.
- Estas plataformas pueden ajustar los ciclos de riego según datos climáticos, humedad y predicciones, maximizando la eficiencia.

6.2.3 Inteligencia Artificial

- **Red Neuronal Convolucional(CNN):** Las CNNs en la agricultura de precision son de gran ayuda, ya que cuentan con la capacidad de procesar datos multimodales como colores, multiespectral, radares, etc. [5].
- **Redes neuronales (MLP):** Estudios han encontrado que es un modelo ideal para predecir variables físicas específicas como la humedad del suelo en comparación con otros modelos como regresión lineal, regresión polinomial y Random Forest [6].
- **eXtreme Gradient Boosting (XGBoost):** ML de aprendizaje supervisado, que busca predecir variables a partir de datos de entrenamiento, especial para grandes conjuntos de datos y que demuestra tener mejor rendimiento que Regresión lineal, Árbol de decisiones y Random Forest [7].

6.2.4 Tecnologías en la nube (AWS)

La computación en la nube de AWS ofrece una gran variedad de herramientas de las que el riego inteligente se puede ayudar, como lo puede ser la gestión de datos, análisis de datos, entre muchas otras [8], las más relevantes con relación a la problemática son:

- **AWS IoT Core:** Servicio que permite conectar, administrar y escalar flotas de dispositivos (sensores, microcontroladores, etc.) a través del protocolo de comunicación de nuestra elección [9].
- **AWS Lambda:** Servicio de computación que ejecuta el código en respuesta a eventos y administra automáticamente los recursos de computación, útil para aplicar procesos de ETL sin necesidad de contar con un servidor [10].
- **AWS S3:** Servicio de almacenamiento de objetos que ofrece escalabilidad, disponibilidad de datos, seguridad y rendimiento, en la agricultura de precisión es ideal para datos históricos y archivos pesados como lecturas de drones[11].

- **AWS Timestream:** Servicio que ofrece motores de bases de datos de serie temporal diseñados específicamente para tareas como las consultas de baja latencia, ideales para tareas como visualización y alertas [12].
- **AWS Glue:** Servicio de ETL que facilita la ejecución de flujos de trabajo para procesar información de diversas fuentes y estructurarla para su uso en machine learning [13].
- **Amazon SageMaker:** Conjunto integral de capacidades de desarrollo de IA que nos permite entrenar, personalizar y desplegar modelos, así como escoger modelos preentrenados [14].
- **Amazon EventBridge:** Permite crear arquitecturas reactivas y automatizadas, útil para conectar distintos componentes de un sistema para que reaccionen a cambios o ejecuciones periódicas [15].

6.3 Antecedentes y Casos Relevantes

6.3.1 Aplicaciones Reales

- En México, **Bayer** ha logrado reducir el consumo de agua hasta en 30% en cultivos de maíz, sandía y melón, gracias a un sistema que analiza datos de suelo, clima, GIS, drones y sensores para dosificación precisa de riego [16].
- En Europa, el proyecto **Life Triplet** recopila más de 700 millones de datos para entrenar modelos predictivos que ayuden en la fertirrigación de viñedos y otros cultivos, con un enfoque de sostenibilidad social, ambiental y económica [17].
- En Tres Cantos (España) un sistema de riego inteligente que usa estaciones meteorológicas logró ahorros de agua del 30% en parques municipales, con control vía internet y radiofrecuencia [18].

6.4 Desafíos y brechas

La implementación de un sistema de riego inteligente implica distintos desafíos que lo limitan a tener una gran escala, los principales serían la dependencia de una fuente de alimentación eléctrica de manera constante e ininterrumpida, lo que en zonas rurales puede ser un reto, los costos iniciales y la capacitación técnica para los agricultores, además de que la precisión y el mantenimiento de los sensores pueden ser comprometidas por condiciones climáticas extremas.

A pesar de que sistemas como Carlota de Bayer logran un impresionante 30% de ahorro en agua, su enfoque principal para obtener datos son la humedad del suelo y el clima, y no el estado mismo del cultivo. Esta limitante de no contar con un monitoreo directo del cultivo, implica que las decisiones de riego pueden ser eficientes, pero no dejan de ser reactivas al entorno, y no proactivas al cultivo, por lo que si el cultivo dejase de absorber el agua adecuadamente, el sistema actual no podría detectarlo a tiempo.

Si bien algunas investigaciones se enfocaron en medir la salud del cultivo bajo un sistema de riego inteligente, esto fue puramente bajo una observación visual [3], esto presenta una brecha, la falta de sensores que midan la fisiología y morfología del cultivo, ya que de momento el sistema no puede saber el estado de las plantas a tiempo para poder tomar una decisión.

7 Propuesta

Se propone el diseño de un Sistema de Riego Proactivo (SRP) que a diferencia de los sistemas de riego actuales que optimizan los recursos hídricos a partir de los datos del entorno, este sistema implementa un diagnóstico sobre la fisiología y la morfología del cultivo para poder tomar decisiones en base al estado de salud actual del cultivo, con el objetivo de tener una agricultura productiva, sostenible y rentable.

7.1 El Sistema de Riego Proactivo consta de 3 capas:

7.1.1 Capa 1: Obtención de datos

Se usarán estaciones que cuenten con todos los sensores necesarios (ambientales, morfológicos y fisiológicos), además de un microcontrolador para recopilar estos datos y transmitirlos.

- **Microcontrolador LoRa 32:** Encargado de recopilar y transmitir los datos de los sensores a través de LoRa.
- **Sensores ambientales:**
 - **Condiciones del suelo:** Sondas de suelo capacitivas a diferentes profundidades (30 cm y 60 cm) en cada sector deseado, encargada de medir la humedad y temperatura del suelo.
 - **Condiciones atmosféricas:** Estación micro climática por cada sector, contendrá:
 - * Termohigrómetro: temperatura y humedad del aire.
 - * Piranómetro: radiación solar.
 - * Pluviómetro: precipitaciones.
 - * Anemómetro: velocidad del viento.
- **Sensores fisiológicos:**
 - **Termómetro infrarrojo:** Encargado de medir la temperatura foliar de la planta, que nos sirve como un indicador del estrés hídrico de la planta.
 - **Sensor flujo de savia:** Se usara en un número reducido de plantas por sector, servirá para indicar el consumo real de agua de la planta.
- **Sensor morfológico:**
 - **Sensores LiDAR:** se usaran para generar un mapeo del campo, y medir con precisión la altura, densidad y volumen de las plantas.

- **Sensor fisiológico:**

- **Cámaras multiespectrales:** Mapeos sobre el estado del nitrógeno en el cultivo.

Cabe aclarar que los datos de los sensores LiDAR y camaras multiespectrales se obtendran a traves de un dron que realizará escaneos periódicos y sus datos tendrán que ser cargados en el servicio de AWS S3 de manera manual.

Gateways LoRaWAN: Serviran para transmitir los datos que reciba del microcontrolador hacia la red implementando AWS IoT Core for LoRaWAN para poder conectar y administrar los dispositivos mas facil [19].

7.1.2 Capa 2: Análisis de datos

Proceso de ETL

1. **Publicación información:** AWS IoT for LoRaWAN al recibir los datos se encarga de convertirlos en formato JSON y procede a publicarlos con el topic adecuado de MQTT en AWS IoT Core.

2. **Extracción:**

- AWS IoT Core ya suscrito al topic de la información emitida atraves de MQTT recibe el mensaje con los datos.
- De manera asíncrona, los datos de mapeo del dron iniciaran el proceso de ETL a través de AWS Glue para posteriormente ser cargados al bucket en S3.

3. **Transformación:** El evento del mensaje con la información invoca una función de AWS Lamdba que es un servicio serverless que ejecutará un script en Pyhton encargado de:

- Limpieza: Validar que los rangos de los datos sean válidos.
- Conversión: Convertir los datos crudos de los sensores.
- Normalización: Escalar todos los datos a un rango en común.

4. **Carga:** Una vez el script haya transformado los datos, estos se almacenaran en dos destinos diferentes:

- **Amazon S3:** Aquí se almacenaran los datos históricos, será lo ideal para obtener una gran cantidad de datos para el modelo y su entrenamiento periódico.
- **Amazon Timestream:** De igual forma aquí se almacenaran los datos, pero para acciones como mostrar gráficas y predicciones diarias es lo ideal gracias a su mecanismo que almacena los datos recientes e históricos de distinta forma.

Modelo de IA

1. **Entrenamiento del modelo:** Este paso debe de ejecutarse de forma periódica para que el modelo pueda aprender de datos históricos acumulados y mejore la toma de decisiones, este proceso será bajo supervisión de un experto en el área agrónoma que etiquetara los datos de los sensores y las imágenes y mapas del dron de manera offline. Se ejecuta AWS Glue para crear la tabla de entrenamiento, esta tabla deberá de ser etiquetada por un experto que identifique el diagnóstico adecuado.
2. **Selección y desarrollo:** Amazon Sagemaker iniciara el proceso de entrenamiento en el cual se explorarán dos opciones:
 - **Modelo de SageMaker:** Debido al enfoque multimodal de los datos de entrenamiento, se seleccionara un modelo de SageMaker basado en CNN para procesar los datos del dron, para después combinar los resultados con los datos de los sensores, posteriormente se utilizara un modelo como XGBoost encargado de hacer el diagnóstico.
 - **Modelo personalizado:** Se seleccionara un framework soportado por SageMaker como TensorFlow, que integrara dos modelos, el primero será un CNN para los datos visuales, y el segundo un MLP para los datos de los sensores, así usando un modelo híbrido que se puede esperar que se obtenga un mejor rendimiento en base a sus recomendaciones [5].

3. **Evaluación de los modelos con la métrica Área bajo la curva Precisión-Recuperación (AUC-PR):** Para asegurar la fiabilidad de los diagnósticos de los modelos se utilizará la métrica AUC-PR, ya que como han demostrado diversos estudios, es lo ideal para el desbalanceo de clases [20] (ya que idealmente siempre habrá mucho más cultivo sano que "no sano"), para obtener el valor de AUC PR, es necesario calcular el área bajo la curva tabulando los siguientes valores:

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}} \quad (1)$$

$$\text{Precisión} = \frac{\text{TP}}{\text{TP} + \text{FP}} \quad (2)$$

4. **Despliegue del modelo:** Ya entrenado y seleccionado el modelo con mejor desempeño será desplegado creando un endpoint, que sirve como una API, esperando que lleguen nuevos datos para analizarlos.

7.1.3 Capa 3: Accionar

Este es el proceso que se llevará a cabo de forma periódica:

1. Se activa un EventBridge llamando a una función lambda que recopile datos del último periodo de tiempo (24 horas) y se envían los datos al endpoint del modelo.

2. El modelo analiza los datos, da un diagnóstico, y se lo devuelve a la función lambda.
3. Lamda envía el diagnostico a dos puntos: un mensaje con instrucciones a través del protocolo MQTT mediante AWS IoT Core con un topic específico para los sistemas automatizados, así como un reporte completo con Amazon Timestream a través de una plataforma y recomendaciones como lo puede ser la fertilización del campo.

8 Impacto

8.1 Impacto económico

- **Agua:** Ahorro de agua arriba del 40% ajustando su consumo al ajustar su consumo a las necesidades del cultivo.
- **Fertilizante:** El análisis del cultivo permite aplicar con precision los insumos unicamente donde sea necesario.
- **Energía:** Un riego eficiente se traduce directamente a menos horas de operación de los sistemas de bombeo.
- **Mano de obra:** La automatización parcial de un sistema de riego libera tiempo del personal, tiempo se puede dedicar a otras tareas.

8.2 Impacto ambiental

- **Conservación agua:** El principal impacto del uso eficiente del agua maximizando su uso.
- **Salud suelo de cultivos:** Al prevenir el riego en exceso se previene las consecuencias de esto, como lo puede ser la erosión y la salinización del suelo.
- **Reducción huella de carbono:** La reducción la energía de los sistemas de riego, así como el uso eficiente de fertilizantes disminuirían los gases de efecto invernadero.

9 Cronograma de actividades

| Semanas | Actividad |
|--------------|--|
| Semana 1-2 | <ul style="list-style-type: none">Definir objetivos generales y específicos.Revisión inicial de literatura: IA, sensores, AWS, soluciones existentes. |
| Semana 3-4 | <ul style="list-style-type: none">Diseño de la arquitectura de hardware y selección de sensores y componentes (LoRa32, microclima, sensores fisiológicos, dron).Diseño de la arquitectura de datos: AWS IoT Core, Lambda, S3, Timestream. |
| Semana 5-6 | <ul style="list-style-type: none">Montaje del prototipo inicial: integración sensores + LoRa32 + LoRaWAN.Configuración del proceso ETL: AWS IoT Core → Lambda → transformación y carga a S3/Timestream. |
| Semana 7-8 | <ul style="list-style-type: none">Recolección de datos de prueba piloto.Pruebas de limpieza, transformación y normalización de datos.Desarrollo inicial del dashboard para visualización. |
| Semana 9-10 | <ul style="list-style-type: none">Preparación de datos para entrenamiento: etiquetado, limpieza y transformación.Entrenamiento de modelos (SageMaker): evaluación de opciones (CNN, XGBoost, MLP, Híbrido, etc.). |
| Semana 11-12 | Despliegue del modelo mediante un endpoint en SageMaker para diagnóstico de datos nuevos. |
| Semana 13-14 | Automatización del diagnóstico: configuración de EventBridge → Lambda → envío de acciones via MQTT + registro en Timestream. |
| Semana 15-16 | Validación del sistema automatizado: simulaciones de riego, ajustes de hardware/software. |
| Semana 17-18 | Evaluación de impacto: ahorro de agua, indicadores de salud del cultivo, mejoras en productividad y sostenibilidad. |
| Semana 19-20 | <ul style="list-style-type: none">Optimización del sistema: ajustes finos de modelo, hardware y comunicación.Definición de requisitos finales para dashboard. |

| Semanas | Actividad |
|----------------|---|
| Semana 21-23 | <ul style="list-style-type: none"> • Preparación del informe final y documentación técnica. • Diseño y refinamiento del dashboard para entrega. |
| Semana 24-25 | Presentación del proyecto, sustentación y difusión de resultados. |

10 Conclusiones

Al concluir esta etapa de planeación de la investigación, vamos en buena dirección para diseñar un sistema de riego inteligente basado en inteligencia artificial que realmente responda a las necesidades del sector agrícola en México. A partir del análisis de la problemática, los antecedentes y las tecnologías disponibles, sabemos que el uso del agua en la agricultura representa un gran porcentaje del consumo nacional, y que muchas pérdidas derivan de prácticas poco eficientes o de sistemas que no incorporan monitoreo del estado real del cultivo. Esto nos reafirma la importancia de incluir no solo sensores de suelo y clima que permitan diagnósticos más precisos.

también revisamos la arquitectura técnica necesaria, hardware, sensores, comunicación, procesamiento de datos en AWS, modelado de IA y automatización y consideramos que es viable montar un prototipo que nos permita recolectar datos suficientes para entrenar modelos y validar si las recomendaciones del sistema mejoran el uso de agua sin afectar la salud del cultivo.

Finalmente, aunque aún no contamos con resultados empíricos definitivos, espero que los beneficios potenciales del sistema incluyan: una reducción significativa en el desperdicio de agua, un mejor estado fisiológico del cultivo (menos estrés, mejor absorción, crecimiento homogéneo) y una mayor sostenibilidad ambiental y económica.

Bibliografía

- [1] CONAGUA. Presidenta Claudia Sheinbaum: Programa nacional de tecnificación de riego permitirá mayor productividad del campo y uso eficiente del agua. Gobierno de México, Marzo 2025. URL <https://www.gob.mx/conagua/prensa/presidenta-claudia-sheinbaum-programa-nacional-de-tecnificacion-de-riego-permitira-mayor-productividad-del-campo-y-uso-eficiente-del-agua?idiom=es>.
- [2] H. Maguey. Más de 80% del agua se va en uso agrícola y de la industria. Gaceta UNAM, oct 2018. URL <https://www.gaceta.unam.mx/crisis-agua-industria/>.
- [3] D. P. Facuy Toledo. Aplicación de sensores IoT e inteligencia artificial para la optimización del riego en cultivos agroecológicos. *Revista Internacional De Investigación Y Desarrollo Global*, 3(2):36–52, 2024. URL <https://doi.org/10.64041/riidg.v3i2.23>.
- [4] Servicio Meteorológico Nacional (SMN). Monitor de sequía en méxico, 2024. URL <https://smn.conagua.gob.mx/es/climatologia/monitor-de-sequia/monitor-de-sequia-en-mexico>.
- [5] M. El Sakka, M. Ivanovici, L. Chaari, and J. Mothe. A review of CNN applications in smart agriculture using multimodal data. *Sensors*, 25(2):472, 2025. doi: 10.3390/s25020472. URL <https://doi.org/10.3390/s25020472>.
- [6] Luca Preite, Arianna Paini, and Giuseppe Vignali. Artificial intelligence-based soil moisture estimation using a combination of in-situ measurements and open-source data. In *Proceedings of the 10th International Food Operations & Processing Simulation Workshop (FOODOPS 2024)*, 2024. URL <https://www.cal-tek.eu/proceedings/i3m/2024/foodops/011/pdf.pdf>.
- [7] Rohit Ravi and Dr Baranidharan. Crop yield prediction using xg boost algorithm. *International Journal of Recent Technology and Engineering (IJRTE)*, 8:3516–3520, 01 2020. URL <http://dx.doi.org/10.35940/ijrte.D9547.018520>.
- [8] Amazon Web Services. Creación de una red de sensores agrícolas con IoT y Amazon DocumentDB. Amazon Web Services Solutions Guidance, sep 2025. URL <https://aws.amazon.com/es/solutions/guidance/building-an-agricultural-sensor-network-using-iot-and-amazon-documentdb/>.
- [9] Amazon Web Services. Aws iot core. Amazon Web Services, sep 2025. URL <https://aws.amazon.com/es/iot-core/>.
- [10] Amazon Web Services. Aws lambda. Amazon Web Services, sep 2025. URL <https://aws.amazon.com/es/lambda/>.
- [11] Amazon Web Services. Amazon s3. Amazon Web Services, sep 2025. URL <https://aws.amazon.com/es/s3/>.
- [12] Amazon Web Services. Amazon timestream. Amazon Web Services, sep 2025. URL <https://aws.amazon.com/es/timestream/>.

- [13] Amazon Web Services. Aws glue. Amazon Web Services, sep 2025. URL <https://aws.amazon.com/es/glue/>.
- [14] Amazon Web Services. Amazon sagemaker. Amazon Web Services, sep 2025. URL <https://aws.amazon.com/es/sagemaker/>.
- [15] Amazon Web Services. Amazon eventbridge. Amazon Web Services, sep 2025. URL <https://aws.amazon.com/es/eventbridge/>.
- [16] Bayer. Carlota: Innovación para el ahorro de agua en agricultura. Bayer México, ago 2025. URL <https://www.bayer.com/es/mx/carlota-innovacion-para-el-ahorro-de-agua-en-agricultura>.
- [17] LifeTriplet. PROYECTO LIFE TRIPLET: digitalización, manejo eficiente fertirrigación para agricultura sostenible. LifeTriplet Project. URL <https://www.lifetriplet.eu/proyecto-life-triplet-digitalizacion-manejo-eficiente-fertirrigacion-para-agricultura-sostenible/>.
- [18] X. Beitia. Un sistema de riego inteligente permite ahorrar un 30% de agua en Tres Cantos. Cadena SER, abr 2025. URL <https://cadenaser.com/cmadrid/2025/04/04/un-sistema-de-riego-inteligente-permite-ahorrar-un-30-de-agua-en-tres-cantos-ser-madrid-norte/>.
- [19] Amazon Web Services. Aws iot core for lorawan. Amazon Web Services, sep 2025. URL <https://aws.amazon.com/es/iot-core/lorawan/>.
- [20] Takaya Saito and Marc Rehmsmeier. The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLoS ONE*, 10(3):e0118432, 2015. URL <https://doi.org/10.1371/journal.pone.0118432>.